Instituto Tecnológico y de Estudios Superiores de Monterrey

Campus Estado de México

TC3006C. Inteligencia artificial avanzada para la ciencia de datos

Grupo: 101

Iván Alexander Ramos Ramírez - A01750817

Fecha de entrega: 14 de Septiembre del 2025

Descripción del dataset Digits:

El dataset Digits forma parte de la librería scikit-learn y corresponde a un conjunto de datos clásico para tareas de clasificación supervisada. Este conjunto contiene 1797 muestras, cada una representando un dígito manuscrito en el rango 0 a 9, lo que constituye un problema de clasificación multiclase con 10 clases distintas.

Cada imagen se encuentra en formato de matriz de 8×8 píxeles, con valores enteros entre 0 y 16 que indican la intensidad en escala de grises. Para facilitar su uso en algoritmos de aprendizaje automático, cada imagen es aplanada en un vector de 64 características numéricas, lo que permite representar los píxeles como un conjunto de variables de entrada.

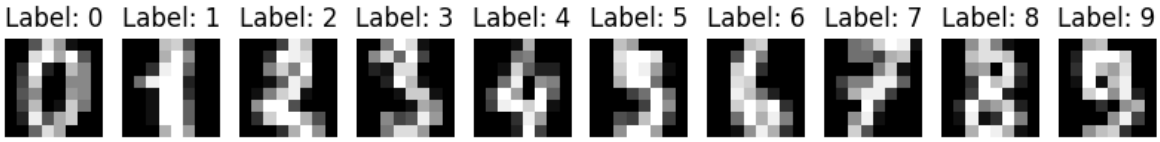

Figura 1 ejemplo de los labels

La variable objetivo (target) corresponde al valor numérico real del dígito representado en cada imagen. Dado que las clases se encuentran relativamente balanceadas, el dataset es apropiado para la evaluación de modelos de clasificación y el análisis de técnicas de regularización y ajuste de hiperparámetros.

Target:
El análisis porcentual de la distribución de los labels muestra que todas las clases tienen una proporción muy similar, alrededor del 10%. Esto indica que el dataset está muy balanceado y no existe predominancia de ninguna clase sobre las demás. Un conjunto de datos balanceado es ideal para el entrenamiento de modelos de clasificación, ya que permite que el modelo aprenda a reconocer todas las clases por igual y evita problemas de sesgo hacia las clases más frecuentes. Por lo tanto, los resultados y métricas obtenidas reflejan de manera justa el desempeño del modelo en todas las clases.

```
Label 0: 9.91%
Label 1: 10.13%
Label 2: 9.85%
Label 3: 10.18%
Label 4: 10.07%
Label 5: 10.13%
Label 6: 10.07%
Label 7: 9.96%
Label 8: 9.68%
Label 9: 10.02%
```

Esto se puede visualizar de mejor manera en el siguiente grafico de distribución de los targets del dataset.

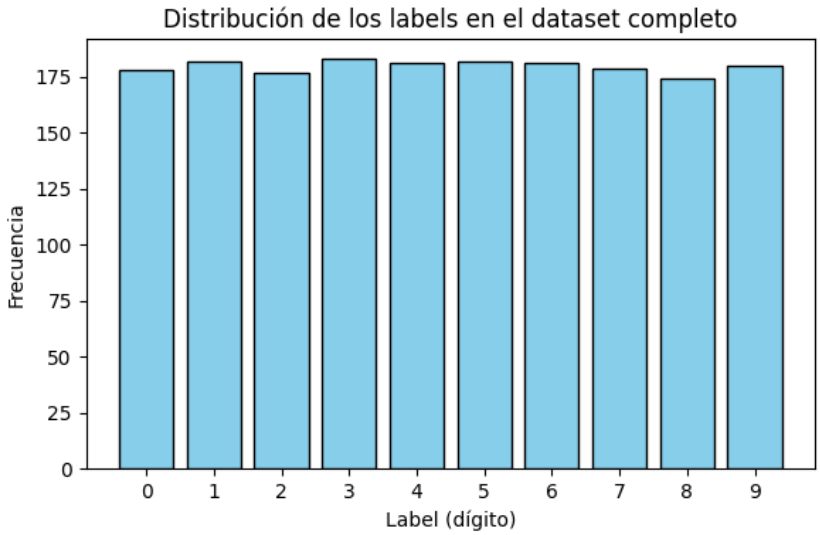

Separación de los conjuntos:

Se realizó una división estratificada de los datos en tres subconjuntos:

```
original Shape: (1797, 64) (1797,)
Train shape: (1265, 64) (1265,) 70.4%
Test shape: (266, 64) (266,) 14.8%
Validation shape: (266, 64) (266,) 14.8%
```

- 70% entrenamiento
- 15% validación
- 15% prueba.

La separación estratificada asegura que la distribución de clases se mantenga similar en cada subconjunto, evitando sesgos y permitiendo una evaluación más confiable. El conjunto de validación es esencial para ajustar hiperparámetros de manera objetiva, ya que, si se usara el conjunto de prueba para este fin, se correría el riesgo de sobreajustar el modelo a los datos de prueba y obtener métricas poco representativas.

Preprocesamiento: Escalado de características

Antes de entrenar la red neuronal, se realizó un escalado de las variables de entrada (features) utilizando la media y desviación estándar calculadas únicamente sobre el conjunto de entrenamiento. Este procedimiento transforma cada píxel para que tenga media cercana a cero y desviación estándar igual a uno.

El motivo principal para escalar las características es mejorar la estabilidad y eficiencia del proceso de aprendizaje. Las redes neuronales son sensibles a la magnitud de las entradas: si los valores de los píxeles varían en rangos muy distintos, las actualizaciones de los pesos pueden volverse inestables y el modelo puede tardar más en converger o incluso no aprender correctamente. Además, el escalado ayuda a que todas las características tengan una influencia comparable en el entrenamiento, evitando que aquellas con mayor rango dominen el proceso de optimización.

Por lo tanto, el escalado es una práctica recomendada en el preprocesamiento de datos para modelos de machine learning, especialmente en redes neuronales, y contribuye a obtener mejores resultados y métricas de desempeño.

Análisis inicial del desempeño del modelo.

```
Accuracy: 0.9774436090225563
Reporte de clasificación:
              precision    recall  f1-score   support

           0      1.000     1.000     1.000        26
           1      0.962     0.926     0.943        27
           2      1.000     1.000     1.000        26
           3      0.964     1.000     0.982        27
           4      0.931     1.000     0.964        27
           5      0.963     0.963     0.963        27
           6      1.000     0.963     0.981        27
           7      1.000     0.962     0.980        26
           8      1.000     0.962     0.980        26
           9      0.964     1.000     0.982        27

    accuracy                          0.977       266
   macro avg      0.978     0.977     0.978       266
weighted avg      0.978     0.977     0.977       266
```

- Accuracy: 0.977 (97.7%), muy alto.
- Precision, recall y f1-score: Todos los valores por clase están cerca de 1.0, lo que significa que el modelo identifica correctamente casi todos los dígitos y comete muy pocos errores.
- Macro y weighted avg: También muy altos, lo que confirma que el desempeño es consistente en todas las clases y no hay clases desbalanceadas afectando el resultado.

Diagnóstico y explicación del grado de bias o sesgo

- Alto bias (subajuste): baja precisión en train y en val/test.
- Medio bias: precisión moderada en train; hay margen de mejora.
- Bajo bias: alta precisión en train; si hay gap grande vs val/test, el problema es varianza.

El modelo no presenta problemas de sesgo ni de sobreajuste. La red neuronal logra aprender los patrones relevantes del dataset y generaliza correctamente a datos no vistos.

```
Train acc=0.999 loss=0.011
Val   acc=0.951 loss=0.279  (gap=0.048)
Test  acc=0.977 loss=0.146 (gap=0.022)
Diagnóstico de bias: bajo
Indicadores: alta precisión en train. Si el gap es grande, el problema es varianza (overfitting)
```

- El sesgo (bias) es bajo: el modelo tiene suficiente capacidad y aprende bien los patrones, por lo que podemos descartar underfitting.
- Este test no muestra evidencia de la presencia de overfitting, la precisión en validación y prueba es alta y cercana a la de entrenamiento, lo que indica buena generalización.

Esto se logra visualizar mejor en la Figura 2

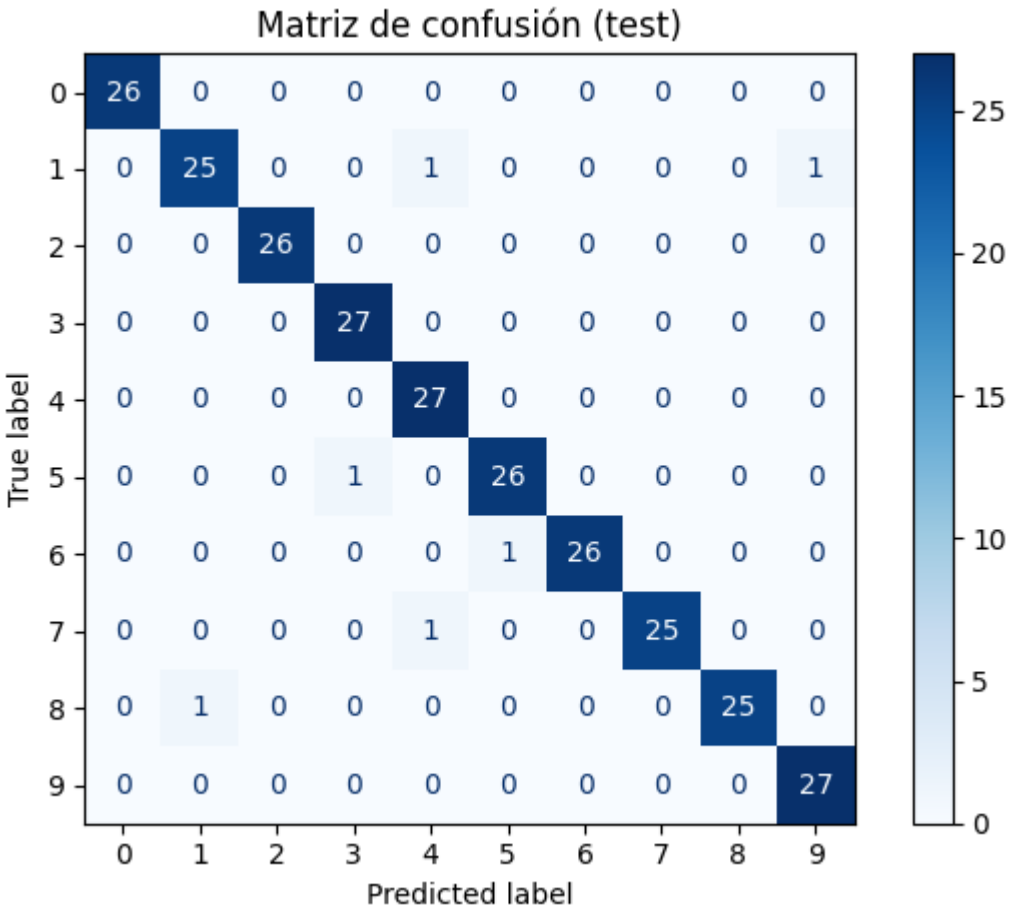

Figura 2 Matriz de confusión.

Diagnóstico y explicación el grado varianza

Para diagnosticar el grado de varianza del modelo, se compara la precisión obtenida en el conjunto de entrenamiento con la precisión en los conjuntos de validación y prueba. La diferencia entre estas métricas, conocida como “gap”, indica qué tan bien el modelo generaliza a datos no vistos.

En la práctica, se utilizan umbrales estándar para clasificar el gap:

- Gap menor a 0.03: varianza baja (el modelo generaliza bien).
- Gap entre 0.03 y 0.08: varianza media (hay algo de sobreajuste, pero no crítico).
- Gap mayor a 0.08: varianza alta (el modelo sobreajusta los datos de entrenamiento).

Estos rangos permiten interpretar objetivamente el desempeño del modelo y tomar decisiones sobre ajustes en la arquitectura o regularización, facilitando el análisis sin necesidad de recurrir a fuentes externas.

```
Varianza (train vs val): medio (gap=0.048)
Varianza (train vs test): bajo (gap=0.022)
Indicadores: hay algo de sobreajuste, pero no crítico. Puedes ajustar regularización o probar más datos.
```

Lo que nos indica en la prueba que hay una ligera varianza más alta al probar el modelo con el split de validación, lo que indica un ligero overfitting, sin embargo, este se puede manejar en los hiperparametros para tener mejores resultados, esto implementando un algoritmo de regularización para evitar que el modelo aprenda mas generalizadamente.

Podemos ver mejor esta diferencia entre fracciones de ambos conjuntos (validacion y testing) en la figura 3.

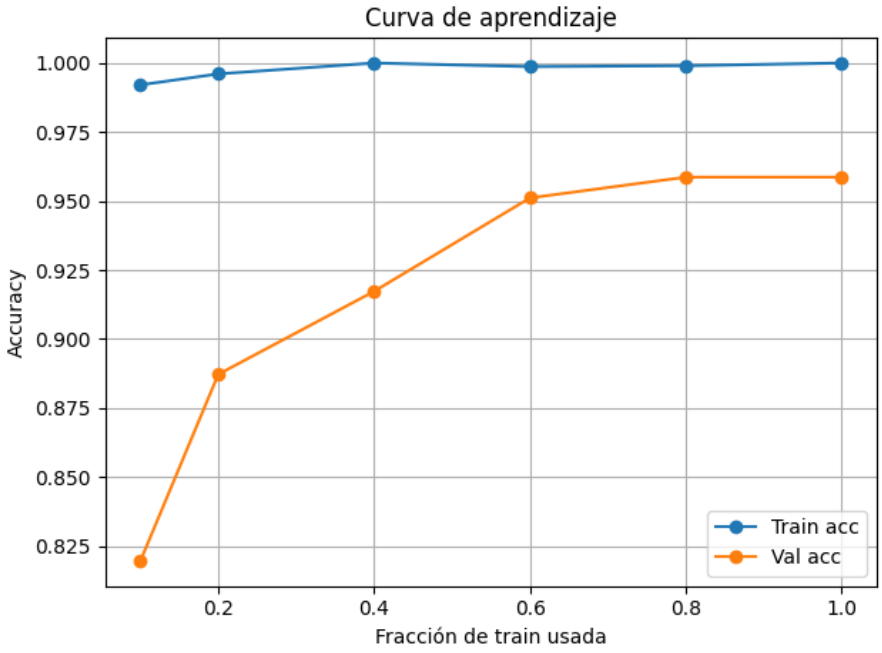

Figura 3

Posteriormente aplicamos Cross-validation para evaluar robustez sobre el conjunto de entrenamiento, esto para evaluar la robustes de nuestro modelo.

Cros validation k=5

```
Epoch   1 | loss=2.4647 | acc=0.206
Epoch  10 | loss=0.9464 | acc=0.732
Epoch  20 | loss=0.3966 | acc=0.914
Epoch  30 | loss=0.2294 | acc=0.955
Epoch  40 | loss=0.1538 | acc=0.972
Epoch  50 | loss=0.1116 | acc=0.983
Epoch  60 | loss=0.0848 | acc=0.990
Epoch  70 | loss=0.0662 | acc=0.992
Epoch  80 | loss=0.0534 | acc=0.994
Epoch  90 | loss=0.0437 | acc=0.996
Epoch 100 | loss=0.0367 | acc=0.997
Epoch 110 | loss=0.0313 | acc=0.998
Epoch 120 | loss=0.0272 | acc=0.999
Epoch 130 | loss=0.0232 | acc=1.000
Epoch  70 | loss=0.0662 | acc=0.992
Epoch  80 | loss=0.0534 | acc=0.994
Epoch  90 | loss=0.0437 | acc=0.996
Epoch 100 | loss=0.0367 | acc=0.997
Epoch 110 | loss=0.0313 | acc=0.998
Epoch 120 | loss=0.0272 | acc=0.999
Epoch 130 | loss=0.0232 | acc=1.000
Epoch 140 | loss=0.0208 | acc=1.000
Epoch 150 | loss=0.0181 | acc=1.000
Epoch 160 | loss=0.0164 | acc=1.000
Epoch 170 | loss=0.0147 | acc=1.000
...
Epoch 180 | loss=0.0218 | acc=0.999
Epoch 190 | loss=0.0196 | acc=0.999
Epoch 200 | loss=0.0177 | acc=0.999
CV Accuracy (5 folds): mean=0.955 ± 0.014
```

Lo que nos muestra esto es que el accurancy de nuestro set de entrenamiento aplicando cross-validation es de alrededor del 96%, mientras que la pedida es alrededor del 18% lo que demuestra que nuestro modelo es sólido.

Regularización.

Para intentar mejorar aun mas nuestro modelo y llegar a un estado aun mas solido podemos implementar la regularización L1, este al penalizar pesos grandes y simplificar el modelo (forzando la generalizacion), se reduce la capacidad del modelo para memorizar el ruido en los datos de entrenamiento.

- Término de Penalización: La suma de los valores absolutos de los pesos (||w||1).
- Efecto Clave: Esparcidad (Sparsity) y Selección de Características

Fuerza a los pesos de las características menos importantes a ser exactamente cero (o muy cercanos a cero).

Al anular pesos, la L1 actúa como un mecanismo de selección de características, creando un modelo más simple y fácil de interpretar al eliminar las conexiones irrelevantes.

Definición de hiperparametros para modelo con regularización L1:

```
modelo_reg_L1 = NeuralNet(
    learning_rate=0.01,
    activation_function='ReLu',
    layer_neurons=[32, 16],
    epoch=200,
    batch_size=32,
    regularization_method='L1',
    lambda_reg=0.01
)
```

Entrenamiento y métricas:

```
Epoch   1 | loss=2.7872 | acc=0.224
Epoch  10 | loss=0.6443 | acc=0.858
Epoch  20 | loss=0.2681 | acc=0.935
Epoch  30 | loss=0.1661 | acc=0.962
Epoch  40 | loss=0.1142 | acc=0.980
Epoch  50 | loss=0.0860 | acc=0.989
Epoch  60 | loss=0.0669 | acc=0.993
Epoch  70 | loss=0.0547 | acc=0.994
Epoch  80 | loss=0.0453 | acc=0.994
Epoch  90 | loss=0.0384 | acc=0.994
Epoch 100 | loss=0.0327 | acc=0.995
Epoch 110 | loss=0.0280 | acc=0.997
Epoch 120 | loss=0.0242 | acc=0.998
Epoch 130 | loss=0.0212 | acc=0.999
Epoch 140 | loss=0.0185 | acc=0.999
Epoch 150 | loss=0.0164 | acc=1.000
Epoch 160 | loss=0.0147 | acc=1.000
Epoch 170 | loss=0.0132 | acc=1.000
Epoch 180 | loss=0.0122 | acc=1.000
Epoch 190 | loss=0.0109 | acc=1.000
Epoch 200 | loss=0.0101 | acc=1.000
=== Modelo Regularizado L1 ===
Train  acc=1.000 loss=0.010
Val    acc=0.966 loss=0.214 gap=0.034
Test   acc=0.966 loss=0.199 gap=0.034
...
    accuracy                         0.966       266
   macro avg      0.967     0.966     0.966       266
weighted avg      0.967     0.966     0.966       266
```

Cros validation k=5:

```
Epoch   1 | loss=3.0260 | acc=0.142
Epoch  10 | loss=1.1284 | acc=0.721
Epoch  20 | loss=0.4835 | acc=0.908
Epoch  30 | loss=0.2719 | acc=0.937
Epoch  40 | loss=0.1850 | acc=0.961
Epoch  50 | loss=0.1373 | acc=0.973
Epoch  60 | loss=0.1058 | acc=0.978
Epoch  70 | loss=0.0836 | acc=0.983
Epoch  80 | loss=0.0678 | acc=0.987
Epoch  90 | loss=0.0555 | acc=0.993
Epoch 100 | loss=0.0467 | acc=0.994
Epoch 110 | loss=0.0398 | acc=0.995
Epoch 120 | loss=0.0345 | acc=0.996
Epoch 130 | loss=0.0301 | acc=0.997
Epoch 140 | loss=0.0268 | acc=0.997
Epoch 150 | loss=0.0239 | acc=0.998
Epoch 160 | loss=0.0211 | acc=0.998
Epoch 170 | loss=0.0194 | acc=0.998
Epoch 180 | loss=0.0172 | acc=0.998
Epoch 190 | loss=0.0159 | acc=0.998
Epoch 200 | loss=0.0144 | acc=0.998
Epoch   1 | loss=2.3871 | acc=0.199
Epoch  10 | loss=1.1643 | acc=0.645
Epoch  20 | loss=0.5937 | acc=0.846
Epoch  30 | loss=0.3524 | acc=0.913
...
Epoch 180 | loss=0.0169 | acc=0.999
Epoch 190 | loss=0.0152 | acc=0.999
Epoch 200 | loss=0.0140 | acc=1.000
CV Accuracy (5 folds): mean=0.955 ± 0.009
```

Selección de la Tasa de Regularización (λ)

Se realizó un proceso de ajuste de hiperparámetros para determinar la tasa de regularización (λ) óptima para la técnica L1. Tras experimentar con diferentes valores, se seleccionó λ=0.1.

Impacto de λ: Valores mayores o menores a 0.1 resultaron en un modelo menos sólido (es decir, con menor rendimiento y/o mayor varianza en los resultados de validación cruzada). La tasa de 0.1 representa el punto de equilibrio que permite que la regularización cumpla su función sin penalizar excesivamente los pesos

Métrica de Comparación	Modelo Sin Regularización	Modelo con Regularización $L1$ ($\lambda = 0.1$)
CV Accuracy (Media)	0.955	0.955
CV Accuracy (Desv. Est.)	$\pm \mathbf{0.014}$	$\pm \mathbf{0.009}$

Aunque el accuracy final de la fase de prueba pudiera ser marginalmente inferior, el modelo con regularización L1 (λ=0.1) es la mejor opción. La reducción significativa en la variabilidad de la CV Accuracy (de ±0.014 a ±0.009) es una prueba concluyente de que este

modelo es más confiable, robusto y tiene una mayor capacidad de generalización que el modelo sin regularización.

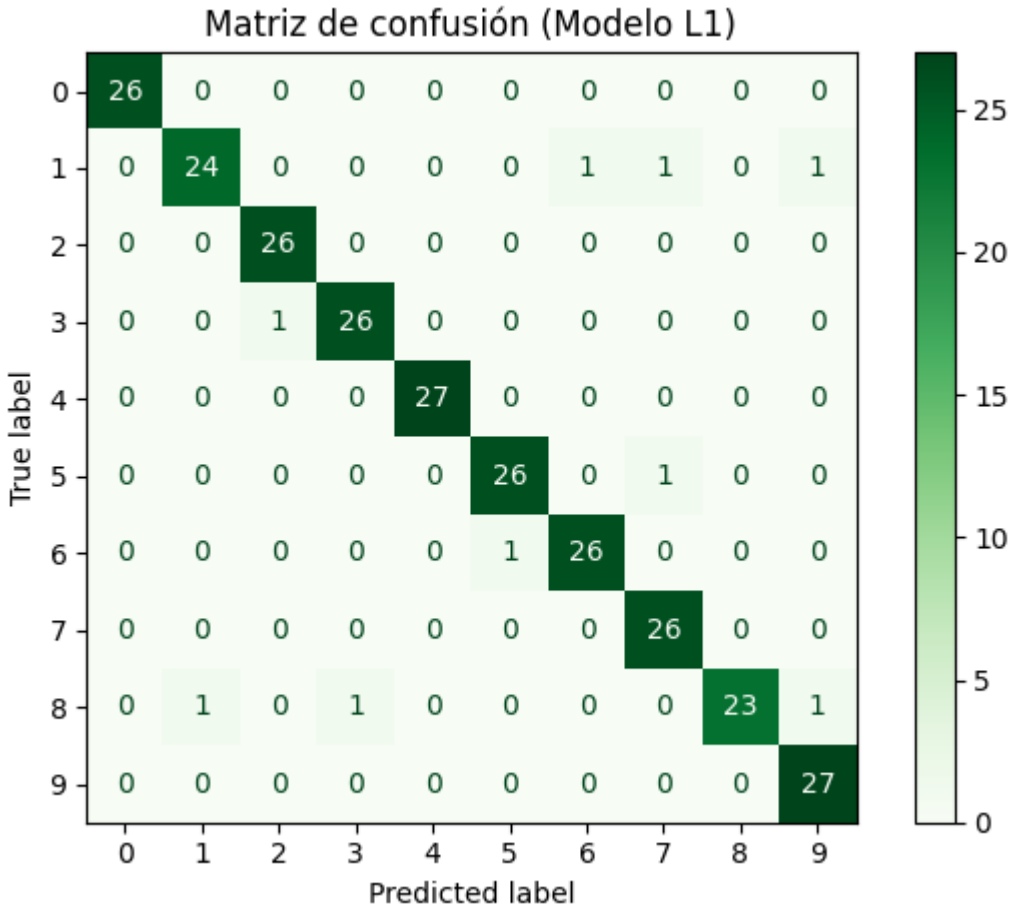

La matriz de confusión no muestra una disminución relevante de la eficacia en comparación con un modelo sin regularización (cuyos resultados de accuracy de CV fueron iguales). De hecho, los resultados en la fase de prueba (test) son prácticamente perfectos. Esto demuestra que la regularización L1 logró su objetivo de aumentar la robustez (como se vio en la reducción de la desviación estándar del CV) sin sacrificar el rendimiento de clasificación en los datos de prueba.

Por lo tanto, este modelo es altamente confiable.